

小分子生物活性阴性数据初步调研

研究现状与可行性设想

当前范围 小分子化合物与蛋白靶点的生物活性数据

结论摘要

公开生物活性数据并不完整代表实际实验空间。数据进入论文和数据库时会受到研究兴趣、筛选流程、报告方式、人工阈值和整理规则的影响。问题不只是正负样本数量不平衡，还包括哪些分子被测试、低活性结果是否保留，以及实验条件是否完整。

初步检索表明，阴性数据训练、inactive 资源、完整筛选结果保存和文献活性抽取均有直接先例。因此，单纯收集更多阴性分子或从论文中抽取活性数据，已不足以构成明确的新意。

仍有研究空间的问题是，不同类型的阴性结果常被压缩为同一个负标签。实测 inactive、截断值、定性无效、相对变差、实验失败、推定阴性、人工 decoy 和未测试数据的科学含义不同。保留这些差异、实验条件和原文证据，再检验其独立价值，可能形成较明确的研究问题。

已有工作做到哪里

研究环节	代表工作	已有成果与限制
阴性数据用于模型	Mervin 等 2015	已比较推定阴性与 active-only 模型。阴性数据入模不是新问题，且推定阴性不等于实测阴性。
inactive 数据资源	InertDB 2025	已整理 inactive 化合物并生成扩展。不能仅靠增加分子数量体现贡献。
完整筛选流程	ECBD 2025	保存 primary assay 与复筛的正负结果。它解决前瞻性保存，不等于历史文献恢复。
真实场景评价	CARA 2024	按 assay 和任务场景组织数据，整体指标可能掩盖部分 assay 的失败。
文献活性抽取	BioMiner 2026 预印本	建立 16,457 条人工标注记录，并从 11,683 篇论文抽取 82,262 条数据；完整记录 F1 约为 0.32。

仍未充分解决的问题

阴性标签缺少统一的科学含义

同一个 negative 标签可能来自实测 inactive、超过检测上限、定性无效、相对变差、数据缺失或人工 decoy。只有部分类型能够提供实验边界信息，unknown 不能自动转成 negative。

实验条件常被弱化

活性是化合物在具体靶点、实验体系、浓度、测量类型和判定阈值下的结果。同一化合物在不同 assay 中可能得到不同结论。若只保存化合物与 0/1 标签，模型无法区分真实差异与实验条件差异。

文献抽取尚未专门评价阴性证据

BioMiner 已覆盖正文、表格、图和化学结构，主要恢复 IC50、Ki 和 Kd 等定量活性。它尚未把定性无效、失败原因、阴性类型和 unknown 的区分作为主要评价任务。

模型收益的来源需要拆开验证

模型改善可能只来自样本增加、类别平衡或数据泄漏。需要在相同数据量和严格切分下比较不同负例来源，并单独检验 assay 上下文的作用。

建议的具体研究问题

在小分子激酶活性文献中，能否可靠识别并分型带实验上下文的阴性观察；与常规数据库标签相比，这些记录是否改善模型在新骨架、新 assay 或时间外推条件下的表现？

激酶活性适合作为起点，因为公开 assay 较多，存在 PKIS 等较完整的测试矩阵，也可以使用 ChEMBL、PubChem 和 CARA 进行核对与评价。这个范围只用于可行性验证，不代表最终必须限制在激酶领域。

研究对象的初步分类

类型	科学含义与处理方式
实测 inactive	在具体 assay 和阈值下未达到活性标准，可以作为条件化负标签。
截断值	例如 $IC_{50} > 10\ \mu M$ ，应保留比较符和检测上限，不伪装成精确值。
定性或相对阴性	适合作为弱标签或成对排序信息，需要保留原句和比较对象。
推定阴性和 decoy	属于构造的训练信号，不具备实测阴性的证据等级。
unknown 或 untested	没有观测，不能自动记为 negative。

最小可行性试验

1. 选取约 50 篇激酶活性论文，覆盖正文、表格和补充材料。人工标注化合物、靶点、测量类型、结果、比较符、单位、实验条件、阴性类型、证据位置和置信度。
2. 使用规则或现有语言模型召回候选记录，比较 precision、recall、证据定位准确率和人工核验时间。自动方法首先用于减少阅读量，不直接替代人工判断。
3. 将新增记录与 ChEMBL 或 PubChem 对照，确认文献是否提供数据库未完整保留的信息。
4. 在等样本量条件下比较 active-only、推定阴性、实测 inactive、文献恢复阴性，以及去除 assay 上下文后的模型结果。

继续或收缩的判断标准

项目适合扩大，需要同时看到三个信号：文献能够稳定提供数据库缺失的阴性观察；自动候选筛选能够减少人工阅读负担；新增数据或上下文在严格切分下产生可重复的模型差异。

如果新增记录很少或上下文不足，不应继续追求大规模数据集。如果能够建立可靠标注但模型收益有限，可以收缩为阴性证据 benchmark 或数据审计研究。如果严格评价下没有新增信息和方法优势，应停止扩展并重新选择问题。

希望讨论的问题

- 研究主线应更侧重数据偏倚、阴性证据抽取，还是下游模型影响？
- 激酶活性是否适合作为第一阶段的验证领域？
- 50 篇论文级别的试验能否作为进入正式研究前的判断依据？
- 后续产出更适合定位为数据集、抽取方法、benchmark，还是数据审计？
- 是否存在可用于对照的内部实验数据、领域知识或相关项目？

主要参考文献

Mervin et al. J Cheminform. 2015. doi:10.1186/s13321-015-0098-y
Chen et al. PLOS ONE. 2019. doi:10.1371/journal.pone.0220113
Tran-Nguyen et al. J Chem Inf Model. 2020. doi:10.1021/acs.jcim.0c00155
Tian et al. Commun Chem. 2024. doi:10.1038/s42004-024-01204-4
An et al. J Cheminform. 2025. doi:10.1186/s13321-025-00999-1
Škuta et al. Nucleic Acids Res. 2025. doi:10.1093/nar/gkae904
Yan et al. BioMiner. arXiv preprint. 2026. arXiv:2604.21508
Lee et al. Chemistry. 2026. doi:10.1002/chem.71208

结论边界 结论基于截至 2026 年 9 月的范围检索，不等于证明此前无人研究。正式立项前仍需系统查重和小规模验证。